



Excelencia que trasciende

DEL VALLE
GRUPO EDUCATIVO

PROYECTO 2

PLUS TI - FRAUDE EN TARJETAS

Security Data Science

Sección 10

Eunice Anahí Mata Ixcayau - 21231

Guatemala, 5 de junio de 2026

Resumen

Se entrenaron y compararon siete modelos LightGBM sobre el dataset sintético BO-VIP Bolivia que contenía 100003 transacciones de tarjetas de crédito VIP, con el objetivo de identificar la estrategia que minimiza la tasa de falsos positivos manteniendo un 90% de detección de fraude. Se implementaron tres funciones de evaluación personalizadas, que intentaban la reducción directa de la proporción de Falsos Positivos (FP), penalización de FP con restricción de recall, y maximización de precisión en alertas. Cada una fue entrenada con los hiper parámetros base y con hiper parámetros optimizados mediante búsqueda bayesiana con Optuna. El modelo base entrenado con AUC-ROC resultó ser el más efectivo, con una proporción de FP de 0.9175 y precisión de 8.25% al 90% de recall.

Para el objetivo B se extendió el enfoque del objetivo A hacia la detección temprana de primeros fraudes en tarjetas.

Se entrenó un modelo LightGBM con datos etiquetados de BO VIP y BR Privado, incorporando variables de primeros eventos por tarjeta y cliente.

El modelo fue ajustado mediante búsqueda de hiperparámetros y selección de umbral, priorizando F1-score y control de falsos positivos.

Finalmente, se aplicó sobre GT para generar probabilidades de fraude y priorizar transacciones tempranas de mayor riesgo.

Metodología

Objetivo A

Se realizó un análisis de los datasets proporcionados en Python, reconstruyendo timestamps completos desde los campos ISO 8583 DE12 y DE13. Se realizó un EDA de distribución de clases, análisis temporal por mes y hora, distribución de montos por clase, y tasas de fraude por MCC (merchant category code). El dataset fue dividido cronológicamente entre los meses de enero a mayo como entrenamiento y junio como pruebas, respetando el orden temporal para evitar data leakage.

Sobre el conjunto de entrenamiento se construyeron features de velocidad como minutos desde la última transacción, contadores en ventanas de 1h y 24h, anomalía de monto, comportamiento de tarjeta (número de transacción, antigüedad de tarjeta, ratio vs promedio histórico), canal de pago (online, CNP, PIN, EMV) y riesgo por categoría de comercio. Las variables categóricas fueron codificadas con LabelEncoder. El conjunto final de entrenamiento contiene 83.836 registros y 38 features.

Objetivo B

Para el objetivo B se desarrolló un modelo supervisado de clasificación binaria que identifica posibles primeros fraudes en tarjetas, priorizando transacciones tempranas o tarjetas con poco historial observado. Se utilizaron los datasets etiquetados de BO VIP y BR Privado como conjunto de entrenamiento, mientras

que el dataset de GT se utilizó como conjunto para generar predicciones, ya que no tiene la etiqueta de fraude.

Se implementó un modelo LightGBM debido a su capacidad para capturar relaciones no lineales. Además de las variables transaccional, se incorporaron variables específicas para detección temprana.

El modelo se ajustó mediante una búsqueda aleatoria de hiperparámetros en las que se tomaron combinaciones como el número de árboles, la tasa de aprendizaje, la profundidad máxima, etc. Para seleccionar el mejor modelo se empleó una partición y se optimizó el umbral de decisión con base en F1-score, considerando también la cantidad de falsos positivos.

Descripción de la implementación práctica

Objetivo A

Se entrenó un modelo base LightGBM con métrica AUC-ROC y scale_pos_weight calculado por desbalance de clases de 19 contra 1. Luego se implementaron tres funciones feval personalizadas compatibles con LightGBM: feval_false_positive_ratio el que minimiza la proporción de falsos positivos, feval_recall_constrained_fp_ratio agregando penalización de 2× si el recall cae bajo 90% y feval_alert_precision_score que maximiza precisión de alertas. Cada feval fue entrenada con los mismos hiper parámetros base para aislar el efecto de la métrica de evaluación.

Para la optimización de hiper parámetros se usó Optuna con 50 trials de búsqueda bayesiana, evaluando en validación el ratio FP al umbral de 90% de recall. Se añadió una restricción de $AUC \geq 0.89$ para descartar trials que deterioran la capacidad discriminativa del modelo. Los mejores hiper parámetros encontrados se usaron para reentrenar las tres fevals, produciendo tres modelos adicionales (con el nombre agregado Optuna), completando un comparativo de siete modelos evaluados sobre el set de test de junio de 2025.

Objetivo B

La implementación práctica del objetivo B consistió en entrenar un modelo LightGBM para detectar primeros fraudes en tarjetas, usando BO VIP y BR Privado como datos etiquetados de entrenamiento y GT Estatal como conjunto objetivo de predicción.

Se incorporaron variables específicas de detección temprana. Para mejorar el modelo se ejecutó una búsqueda aleatoria de 12 trials, probando hiperparámetros como n_estimators, learning_rate, num_leaves, max_depth, entre otros valores, n_estimators=800, learning_rate=0.045, num_leaves=95, max_depth=11, min_child_samples=90, subsample=0.8, colsample_bytree=0.95, reg_alpha=0.1 y reg_lambda=0.1.

Finalmente, se optimizó el umbral de decisión en validación, priorizando F1-score y control de falsos positivos, y se generaron probabilidades de fraude para las transacciones de GT Estatal.

Análisis de los resultados

Objetivo A

Los siete modelos alcanzaron exactamente el mismo recall de 90.10%, TP=655, FN=72; lo que convierte al ratio FP en el único diferenciador real. El modelo base lidera con FP=7.285, seguido por Recall_Constrained_FP_Ratio con FP=7.637 y los modelos Optuna en posiciones intermedias de FP=7.806. El peor resultado fue Recall_Constrained_FP_Ratio_Optuna con FP=7.940 y un umbral operacional de 0.004, lo que implica que casi toda transacción sería marcada como sospechosa; este es completamente inviable en producción. Los modelos FP_Ratio y Alert_Precision entrenados con params base son idénticos en todas las métricas, indicando que para este dataset ambas fevals convergen al mismo comportamiento.

En el experimento se observó que las fevals diseñadas para reducir falsos positivos produjeron más falsos positivos que el modelo base. La causa es un desajuste de umbral, las fevals calculan su métrica al umbral fijo de 0.5 durante el entrenamiento, pero la evaluación final ocurre al umbral operacional (~0.07) que garantiza 90% de recall. El modelo entrenado con AUC, al ser una métrica agnóstica al umbral, genera probabilidades mejor calibradas globalmente, lo que se traduce en mayor precisión a cualquier nivel de recall. Este resultado es muy valioso para este tipo de dataset desbalanceado con umbral operacional dinámico, AUC sigue siendo la métrica de entrenamiento más robusta.

Conclusiones

El modelo base LightGBM entrenado con AUC-ROC fue el más efectivo del Objetivo A, alcanzando el menor ratio de falsos positivos (0.9175) y la mayor precisión 94% de detección de fraude, superando a los seis modelos con métricas personalizadas y optimización bayesiana.

Las funciones feval diseñadas para reducir falsos positivos no mejoraron al modelo base en ninguna configuración. El entrenamiento con AUC produce probabilidades mejor calibradas que las fevals basadas en umbral fijo (0.5), resultando en mejor precisión al umbral operacional real (~0.07) requerido para alcanzar el 90% de recall.

Para el objetivo b, el mejor modelo obtuvo en validación un F1-score de 0.8108, precisión de 0.9604, recall de 0.7015, ROC-AUC de 0.8889 y PR-AUC de 0.7841. Además, presentó una tasa de falsos positivos de 0.12% sobre transacciones legítimas, aspecto relevante dado que las alertas incorrectas pueden generar costos operativos, revisiones manuales y fricción con clientes.

Finalmente, el modelo seleccionado se reentrenó utilizando todo el conjunto etiquetado disponible y se aplicó sobre GT Estatal. Se identificaron 1,324 transacciones potencialmente fraudulentas, equivalentes al 1.32% del total evaluado.